

Covid and Pneumonia Detection

Eddy Montenegro Diego Bances Alessandro Alecio



Introducción

Este proyecto utiliza inteligencia artificial y visión por computadora para detectar automáticamente COVID-19 y neumonía a partir de imágenes de rayos X del tórax. Desarrollamos una red neuronal convolucional (CNN) que clasifica estas imágenes en tres categorías: COVID-19, neumonía y normales. El uso de este tipo de tecnología puede acelerar el diagnóstico y mejorar su precisión, apoyando a los profesionales de la salud en su labor diaria.

Descripción del Dataset

El dataset utilizado en este proyecto está compuesto por imágenes de rayos X del tórax, categorizadas en tres clases: COVID-19, neumonía y normales. A continuación se detalla la distribución de las imágenes en los conjuntos de entrenamiento y prueba:

- Entrenamiento:
 - 70 imágenes de neumonía - 110 con oversampling
 - 70 imágenes normales - 110 con oversampling
 - 111 imágenes de COVID-19
- Prueba:
 - 20 imágenes de neumonía
 - 20 imágenes normales
 - 26 imágenes de COVID-19

Metodologia

Para desarrollar un modelo de detección de COVID-19 y neumonía a partir de imágenes de rayos X, se siguieron varios pasos clave. Primero, todas las imágenes fueron redimensionadas a 100x100 píxeles y convertidas a escala de grises, ya que se determinó que el color no aportaba información adicional relevante. Además, las imágenes fueron normalizadas para mejorar la estabilidad del modelo durante el entrenamiento. Dado que el dataset estaba desbalanceado, se aplicaron técnicas de oversampling en el conjunto de entrenamiento para equilibrar las clases de COVID-19, neumonía y normales. Esto aseguró que el modelo recibiera una cantidad suficiente de ejemplos de cada categoría. El modelo desarrollado es una red neuronal convolucional (CNN) con múltiples capas convolucionales seguidas de capas de pooling y capas totalmente conectadas. Se entrenó utilizando el conjunto de datos preprocesado y balanceado, implementando técnicas de regularización como dropout para prevenir el sobreajuste. Finalmente, se evaluó el rendimiento del modelo con el conjunto de prueba, analizando métricas como precisión y porcentaje de aciertos de cada clase.

Codigo QR e Informacion de contacto

Eddy Montenegro - 21000630 - eddy.montenegro@galileo.edu
Diego Bances - 20001745 - diego.bances@galileo.edu
Alessandro Alecio - 21001224 - sebastian.alecio@galileo.edu



Resultados

- Modelo 1:** Arquitectura básica con pocas capas convolucionales y de pooling.
- Modelo 2:** Arquitectura avanzada con múltiples capas convolucionales y de pooling, incluyendo técnicas de regularización y optimización más complejas.
- Modelo 3:** Arquitectura intermedia con un mayor número de capas y técnicas de regularización como dropout.

Entre los tres modelos evaluados, el Modelo 2 se destacó por su desempeño superior en términos de precisión, sensibilidad y especificidad. Este modelo logró los mejores resultados gracias a su arquitectura más profunda y compleja, que permitió capturar mejor las características relevantes en las imágenes de rayos X.

- Precisión:** El Modelo 2 alcanzó una precisión superior al 90 %, superando a los otros dos modelos. A comparación con el modelo 3 que detecta mejor los casos de covid y sano, pero neumonia es muy impreciso.
- Sensibilidad:** El Modelo 2 mostró una alta sensibilidad, especialmente en la detección de casos de COVID-19 y neumonía.
- Especificidad:** La especificidad también fue notablemente alta en el Modelo 2, reduciendo la tasa de falsos positivos.

Modelo	Accuracy	% COVID	% Neumonía	% Sanos
Modelo 1	84.85 %	92.31 %	65.00 %	95.00 %
Modelo 2	86.36 %	92.31 %	85.00 %	80.00 %
Modelo 3	86.36 %	100.00 %	65.00 %	90.00 %

Cuadro 1. Desempeño de los diferentes modelos de CNN evaluados.

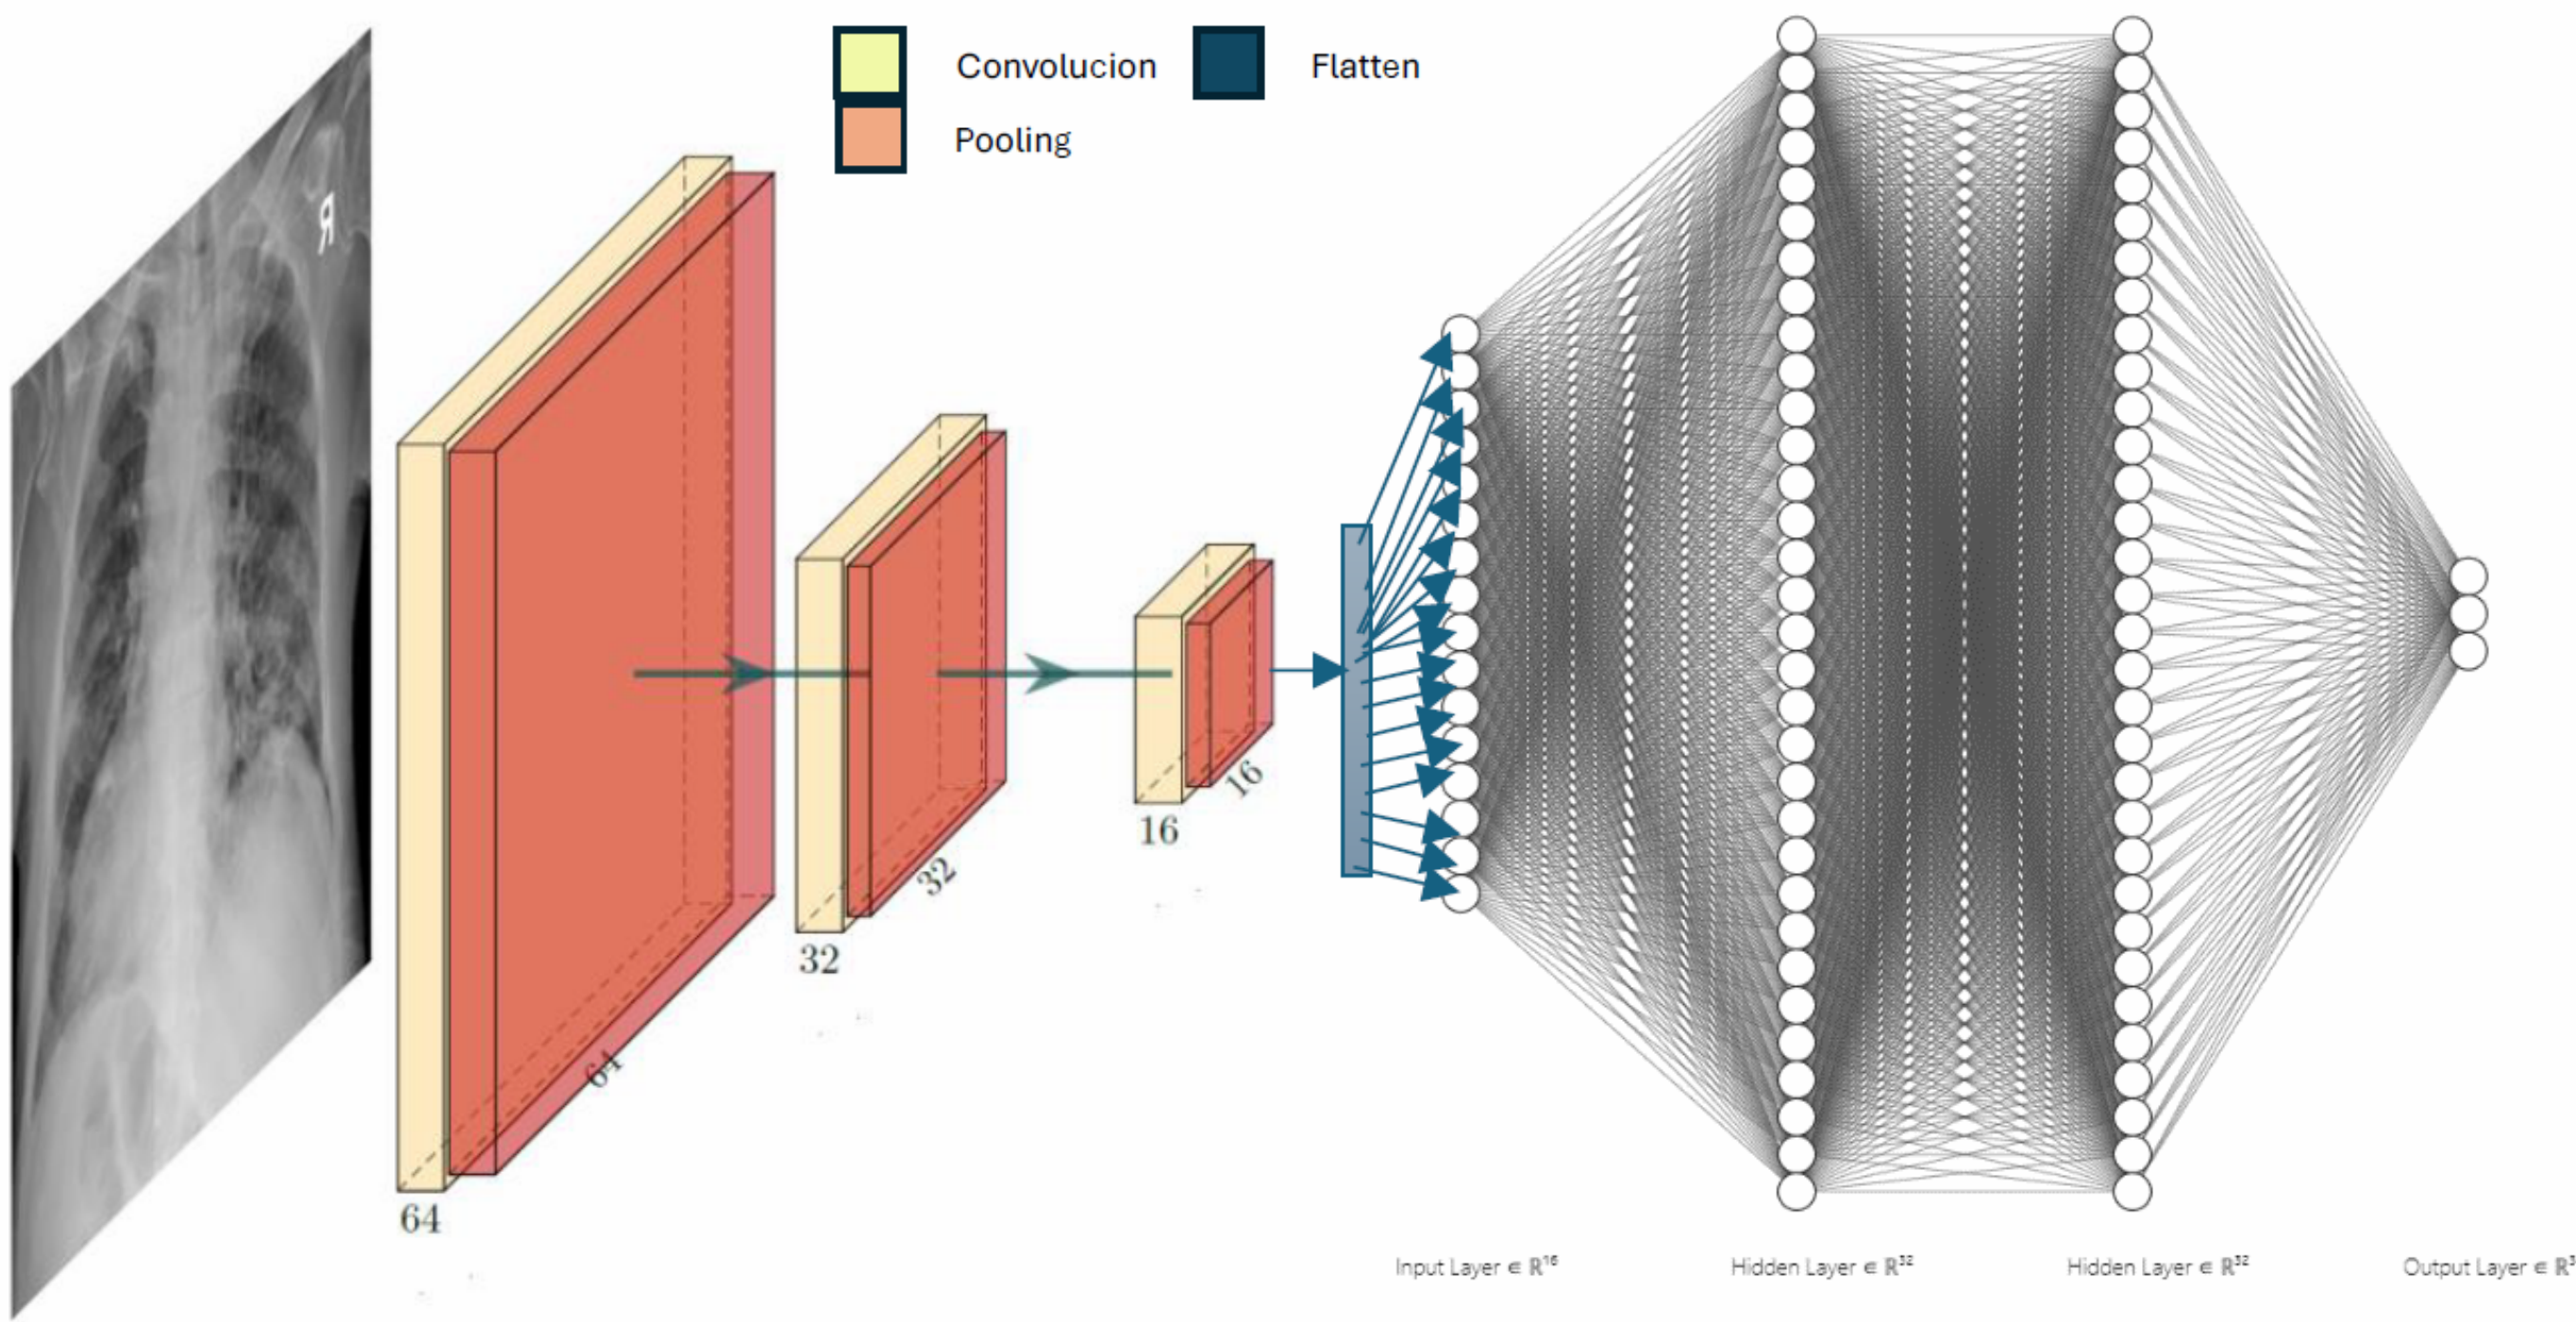


Imagen 1. Arquitectura del modelo 2




Imagen 2. Matriz de confusión del modelo 2

Conclusiones

Este proyecto demuestra el potencial de las redes neuronales convolucionales (CNN) para la detección automática de COVID-19 y neumonía a partir de imágenes de rayos X del tórax. A través de la evaluación de tres modelos con diferentes arquitecturas, se identificó que una arquitectura avanzada con múltiples capas convolucionales y técnicas de regularización ofrece los mejores resultados en términos de precisión, sensibilidad y especificidad. Las redes neuronales convolucionales son efectivas para la clasificación de imágenes médicas, logrando altos niveles de precisión en la detección de COVID-19 y neumonía. La estandarización de las imágenes, incluyendo el redimensionamiento y la conversión a escala de grises, es crucial para el rendimiento del modelo, y la aplicación de técnicas de oversampling fue esencial para mitigar el desbalance de clases y mejorar el rendimiento del modelo.

Mejoras a futuro

Aunque los resultados obtenidos en este proyecto son prometedores, existen varias áreas en las que se pueden realizar mejoras para aumentar la precisión y eficacia del modelo. Algunas de estas mejoras incluyen:

Incrementar la cantidad de imágenes en el dataset, especialmente para las clases menos representadas, podría mejorar significativamente el rendimiento del modelo y su capacidad de generalización.

Explorar y probar arquitecturas más avanzadas de redes neuronales, como las redes neuronales profundas y las redes neuronales convolucionales residuales (ResNets), podría mejorar aún más el rendimiento.

Aplicar técnicas de augmentación de datos, como rotaciones, traslaciones y cambios de brillo, podría ayudar a aumentar la diversidad del dataset de entrenamiento y mejorar la robustez del modelo.

Implementar un sistema de actualización continua del modelo para incorporar nuevas imágenes y mejorar su precisión y relevancia a lo largo del tiempo.

Estas mejoras pueden contribuir a desarrollar una herramienta de diagnóstico más precisa y confiable, con un mayor impacto en la práctica clínica y en la detección temprana de enfermedades respiratorias como el COVID-19 y la neumonía.